

FINOR × BOOTCAMP DATA SCIENCE 2026

Guia de Dados & EDA

Index Tracking: S&P100 e IBOVESPA

1. Contexto: O Que São os Dados que Vocês Vão Trabalhar?.....	4
1.1 O Que é um Índice de Ações?.....	4
1.2 O Que é Capitalização de Mercado e Por Que Importa?.....	4
1.3 O Que é Index Tracking e Por Que os Dados Importam?.....	5
2. Entendendo os Dados: O Que Cada Coluna Significa?.....	5
2.1 As Colunas do Yahoo Finance.....	5
2.2 Preço vs. Retorno,Uma Distinção Fundamental.....	6
2.3 Por Que Trabalhar com Retornos e Não com Preços?.....	7
2.4 O Que São os Dados do Índice?.....	7
3. Coleta dos Dados: Passo a Passo.....	8
3.1 De Onde Tirar a Lista de Ações.....	8
3.2 Código Completo,Download dos Dados.....	8
3.3 Calculando os Retornos.....	10
4. EDA - Parte 1: Qualidade dos Dados.....	11
4.1 Análise de Dados Faltantes.....	11
4.2 Como Tratar os Dados Faltantes.....	12
4.3 Identificação de Outliers nos Retornos.....	13
5. EDA - Parte 2: Explorando os Retornos das Ações.....	14
5.1 Performance Normalizada,O Gráfico Mais Importante.....	14
5.2 Estatísticas Descritivas dos Retornos.....	15
5.3 Retorno por Período,Identificando Crises.....	15
5.4 Correlação com o Índice,A Análise Central do Projeto.....	16
6. EDA - Parte 3: Correlação Entre Ações e Análise por Setor.....	18
6.1 Matriz de Correlação Entre Ações.....	18
6.2 Análise por Setor da Economia.....	18
7. EDA - Parte 4: Volatilidade e Períodos de Crise.....	20
7.1 Linha do Tempo dos Principais Eventos.....	20
7.2 Volatilidade Móvel,Como o Risco Muda ao Longo do Tempo.....	20
7.3 Comparativo S&P100 vs. IBOVESPA.....	21
8. Prompts de IA: Para Aprofundar o Entendimento dos Dados.....	22
9. Checklist: O que Apresentar.....	24
9.1 O que os Professores/Avaliadores Querem Ver.....	24
9.2 Checklist de Entregas Técnicas.....	24

1. Contexto: O Que São os Dados que Vocês Vão Trabalhar?

Antes de abrir qualquer planilha ou rodar qualquer código, o grupo precisa responder uma pergunta fundamental: **o que esses dados representam no mundo real?** Em finanças, entender o dado é tão importante quanto processá-lo.

1.1 O Que é um Índice de Ações?

Um índice de ações é um **número que resume o desempenho de um conjunto de empresas** em uma bolsa de valores. Ele funciona como um termômetro do mercado: se o índice sobe, o mercado está bem; se cai, o mercado está mal.

Índice	Bolsa	O que mede	Composto por
S&P 100	NYSE / Nasdaq (EUA)	Desempenho das 100 maiores empresas americanas por capitalização de mercado	Apple, Microsoft, Amazon, Google, Berkshire, etc.
IBOVESPA (IBOV)	B3 (Brasil)	Desempenho das ações mais negociadas da bolsa brasileira	Petrobras, Vale, Itaú, Bradesco, WEG, etc.



Por que índices existem?

Imagine que você quer saber se 'o mercado americano foi bem hoje'. Seria impossível olhar para as 5.000 ações negociadas na NYSE individualmente. O S&P100 resolve isso: ele pega as 100 maiores empresas, pondera pelo tamanho de cada uma (capitalização de mercado) e gera um único número que representa o conjunto.

É como uma **média ponderada** do desempenho das maiores empresas do país.

1.2 O Que é Capitalização de Mercado e Por Que Importa?

A capitalização de mercado de uma empresa é simplesmente: **Preço da ação × Número de ações em circulação**. Ela representa o valor total que o mercado atribui à empresa.

Empresa (exemplo)	Preço da ação	Ações em circulação	Capitalização de mercado
Apple (AAPL)	~US\$ 200	~15,4 bilhões	~US\$ 3,08 trilhões
Petrobras (PETR4)	~R\$ 38	~13 bilhões	~R\$ 494 bilhões

No S&P100 e no IBOVESPA, **o peso de cada ação no índice é proporcional à sua capitalização de mercado**. Isso significa que a Apple tem muito mais influência sobre o S&P100 do que uma empresa pequena. Quando a Apple sobe 1%, o índice sente mais do que quando uma empresa menor sobe 1%.

1.3 O Que é Index Tracking e Por Que os Dados Importam?

O projeto pede que vocês **repliquem o comportamento do índice usando menos ações**. Para isso, precisam entender profundamente o que os dados de cada ação representam, porque serão eles que o modelo vai usar para decidir quais ações incluir e quanto alocar.

Pergunta central desta semana

Com os dados históricos das ações do S&P100 e do IBOV, o grupo deve ser capaz de responder na apresentação:

- Quais ações têm comportamento mais parecido com o índice?
- Quais ações 'andam juntas' (alta correlação)?
- Quais dados estão faltando ou com problemas?
- Quais períodos foram de crise e como os dados refletem isso?
- O que os dados nos dizem sobre a dificuldade de replicar cada índice?

2. Entendendo os Dados: O Que Cada Coluna Significa?

Quando vocês baixarem os dados do Yahoo Finance, receberão uma tabela com algumas colunas para cada ação. É fundamental entender o que cada uma representa antes de usar qualquer dado.

2.1 As Colunas do Yahoo Finance

Coluna	Nome completo	O que representa	Qual usar?
Open	Preço de abertura	Preço da primeira negociação do dia	Raramente
High	Preço máximo	Maior preço negociado no dia	Raramente
Low	Preço mínimo	Menor preço negociado no dia	Raramente
Close	Preço de fechamento	Último preço negociado no dia, preço 'oficial' do dia	Sim, mas...

Coluna	Nome completo	O que representa	Qual usar?
Adj Close	Fechamento ajustado	Close corrigido por dividendos, splits e bonificações	✅ USE ESTE
Volume	Volume negociado	Quantidade de ações negociadas no dia	Para análise de liquidez

⚠️ Por que usar Adj Close e NÃO Close?

Imagine uma ação que custa R\$ 100. A empresa decide fazer um **split** (desdobramento) 2 por 1: cada ação vira 2 ações e o preço cai para R\$ 50. O investidor não perdeu nada, ele tem o dobro de ações pela metade do preço.

Mas se você olhar só o preço Close, verá uma 'queda' de 50% que nunca aconteceu.

O **Adj Close** corrige isso automaticamente, ajustando todos os preços históricos para refletir esses eventos. Use sempre o Adj Close para análise histórica.

O mesmo vale para **dividendos**: quando uma empresa paga dividendos, o preço da ação cai pelo valor do dividendo. O Adj Close já incorpora essa correção.

2.2 Preço vs. Retorno, Uma Distinção Fundamental

Em finanças, analistas raramente trabalham diretamente com o **preço** das ações. Eles trabalham com os **retornos**, a variação percentual de um período para o outro. Entender essa diferença é crucial para o projeto.

1 2 3 4 Retorno Simples vs. Retorno Logarítmico

Retorno simples: $r_t = (P_t - P_{t-1}) / P_{t-1}$ = variação percentual

- Exemplo: ação sai de R\$100 para R\$110 → retorno = 10%
- Intuitivo, fácil de comunicar

Retorno logarítmico: $r_t = \ln(P_t / P_{t-1})$

- Exemplo: ação sai de R\$100 para R\$110 → retorno = $\ln(1,10) \approx 9,53\%$
- Preferido em finanças quantitativas porque:
 - Se soma ao longo do tempo (aditivo)
 - Aproximadamente simétrico (facilita estatística)
 - Mais robusto em períodos de alta volatilidade

Para este projeto, **qualquer um dos dois funciona**, escolham um e mantenham consistência em todo o código. Documentem a escolha no notebook.

2.3 Por Que Trabalhar com Retornos e Não com Preços?

- **Comparabilidade:** uma ação a R\$ 5 e outra a R\$ 500 não são diretamente comparáveis em preço, mas são comparáveis em retorno.
- **Estacionariedade:** séries de preços tendem a crescer ao longo do tempo (não estacionárias), enquanto retornos oscilam em torno de uma média (mais estacionários, melhor para modelagem).
- **Interpretabilidade:** um retorno de 2% significa a mesma coisa para qualquer ação, independente do preço absoluto.
- **Normalização natural:** retornos já são uma forma de normalização, não precisamos escalar os dados antes de comparar ações.

2.4 O Que São os Dados do Índice?

Além dos dados de cada ação individual, vocês precisarão dos dados do próprio índice (S&P100 e IBOVESPA). Esses dados têm uma diferença importante:

Dado	Ticker no Yahoo Finance	O que representa
S&P 100 (índice)	^OEX	Valor do índice S&P100, número calculado pela S&P com base nas 100 ações ponderadas
IBOVESPA (índice)	^BVSP	Pontuação do IBOV, número calculado pela B3 com base nas ações mais líquidas ponderadas
Apple (ação individual)	AAPL	Preço da ação da Apple na Nasdaq
Petrobras (ação individual)	PETR4.SA	Preço da ação da Petrobras na B3 (sufixo .SA obrigatório no Yahoo Finance)

Atenção ao sufixo .SA para ações brasileiras

No Yahoo Finance, todas as ações brasileiras precisam do sufixo **.SA** para serem reconhecidas. Exemplos:

PETR4 → PETR4.SA VALE3 → VALE3.SA
ITUB4 → ITUB4.SA BBDC4 → BBDC4.SA

O índice IBOVESPA (^BVSP) NÃO leva o sufixo .SA, ele é identificado pelo ^. O índice S&P100 é identificado por ^OEX.

3. Coleta dos Dados: Passo a Passo

O Yahoo Finance disponibiliza dados históricos gratuitos de praticamente todas as ações do mundo. A biblioteca **yfinance** do Python é a forma mais eficiente de acessá-los.

3.1 De Onde Tirar a Lista de Ações

Índice	Onde buscar a lista de ações	O que copiar
S&P 100	Wikipedia: 'S&P 100' → tabela 'Components'	Coluna 'Symbol', são os tickers como AAPL, MSFT, etc.
IBOVESPA	B3: b3.com.br → Índices → IBOVESPA → Composição	Coluna 'Código', são tickers como PETR4, VALE3. Adicionar .SA
Alternativa IBOV	statusinvest.com.br → Índices → IBOV	Lista completa com pesos atuais de cada ação



Dica, Extrair a lista da Wikipedia automaticamente

Ao invés de copiar manualmente, o pandas consegue ler tabelas HTML diretamente:

```
import pandas as pd
url = 'https://en.wikipedia.org/wiki/S%26P_100'
tabelas = pd.read_html(url)
sp100 = tabelas[2] # geralmente é a terceira tabela
tickers = sp100['Symbol'].tolist()
```

Teste e ajuste o índice [2] conforme necessário, a Wikipedia muda o layout às vezes.

3.2 Código Completo, Download dos Dados

```
import yfinance as yf
import pandas as pd
import numpy as np
import warnings
warnings.filterwarnings('ignore')

# =====
# PASSO 1: Definir a lista de tickers
# =====

# S&P 100, lista parcial de exemplo (adicione todos os 100)
tickers_sp100 = [
    'AAPL', 'MSFT', 'AMZN', 'GOOGL', 'GOOG', 'META', 'NVDA',
    'TSLA', 'BRK-B', 'JPM', 'JNJ', 'V', 'PG', 'UNH', 'HD',
```



```

'MA', 'DIS', 'BAC', 'ABBV', 'XOM', 'CVX', 'LLY', 'AVGO',
# ... adicionar todos, buscar lista atualizada na Wikipedia
]

# IBOVESPA, lista parcial de exemplo (adicione todos)
tickers_ibov = [
    'PETR4.SA', 'VALE3.SA', 'ITUB4.SA', 'BBDC4.SA', 'ABEV3.SA',
    'WEGE3.SA', 'RENT3.SA', 'MGLU3.SA', 'SUZB3.SA', 'BBAS3.SA',
    'B3SA3.SA', 'BPAC11.SA', 'RDOR3.SA', 'GGBR4.SA', 'CSNA3.SA',
    # ... adicionar todos, buscar lista atualizada na B3
]

# Tickers dos índices
ticker_idx_sp100 = '^OEX'
ticker_idx_ibov = '^BVSP'

# =====
# PASSO 2: Definir o período (7 anos conforme briefing)
# =====
inicio = '2018-01-01'
fim = '2025-05-01'

# =====
# PASSO 3: Baixar os dados
# =====
print('📥 Baixando S&P100...')
dados_sp100 = yf.download(tickers_sp100, start=inicio, end=fim,
                          auto_adjust=True, progress=False)['Close']
indice_sp100 = yf.download(ticker_idx_sp100, start=inicio, end=fim,
                          auto_adjust=True, progress=False)['Close']

print('📥 Baixando IBOVESPA...')
dados_ibov = yf.download(tickers_ibov, start=inicio, end=fim,
                        auto_adjust=True, progress=False)['Close']
indice_ibov = yf.download(ticker_idx_ibov, start=inicio, end=fim,
                        auto_adjust=True, progress=False)['Close']

# =====
# PASSO 4: Salvar localmente (evita baixar toda vez!)
# =====
dados_sp100.to_csv('sp100_precos.csv')
dados_ibov.to_csv('ibov_precos.csv')
indice_sp100.to_csv('sp100_indice.csv')
indice_ibov.to_csv('ibov_indice.csv')

# =====
# PASSO 5: Verificação rápida
# =====
print(f'\n✅ S&P100: {dados_sp100.shape[1]} ações × {dados_sp100.shape[0]} pregões')
print(f'\n✅ IBOV: {dados_ibov.shape[1]} ações × {dados_ibov.shape[0]} pregões')
print(f'\nPeríodo S&P100: {dados_sp100.index[0].date()} → {dados_sp100.index[-1].date()}')
print(f'\nPeríodo IBOV: {dados_ibov.index[0].date()} → {dados_ibov.index[-1].date()}')
print('\nPrimeiras linhas S&P100:')
print(dados_sp100.head(3))

```

3.3 Calculando os Retornos

```
# =====
# Calcular retornos, FAÇA ISSO LOGO APÓS O DOWNLOAD
# =====

# Retorno logarítmico diário (recomendado para finanças quantitativas)
ret_sp100 = np.log(dados_sp100 / dados_sp100.shift(1)).dropna()
ret_ibov = np.log(dados_ibov / dados_ibov.shift(1)).dropna()
ret_idx_sp = np.log(indice_sp100 / indice_sp100.shift(1)).dropna()
ret_idx_ib = np.log(indice_ibov / indice_ibov.shift(1)).dropna()

# Alternativa: retorno simples percentual
# ret_sp100 = dados_sp100.pct_change().dropna()

print('Formato dos retornos S&P100:', ret_sp100.shape)
print('Formato dos retornos IBOV: ', ret_ibov.shape)
print(f'\nRetorno médio diário do S&P100: {ret_idx_sp.mean():.4%}')
print(f'\nRetorno médio diário do IBOV: {ret_idx_ib.mean():.4%}')
print(f'\nVolatilidade diária S&P100: {ret_idx_sp.std():.4%}')
print(f'\nVolatilidade diária IBOV: {ret_idx_ib.std():.4%}')

# Salvar retornos
ret_sp100.to_csv('sp100_retornos.csv')
ret_ibov.to_csv('ibov_retornos.csv')
```



Atenção, EUA e Brasil têm calendários diferentes

Os mercados americano e brasileiro têm feriados diferentes. Isso significa que o S&P100 pode ter dados para um dia em que o IBOV não tem (e vice-versa).

Quando vocês forem **comparar os dois índices**, precisarão alinhar as datas:

```
datas_comuns = ret_idx_sp.index.intersection(ret_idx_ib.index)
ret_sp_alinhado = ret_idx_sp.loc[datas_comuns]
ret_ib_alinhado = ret_idx_ib.loc[datas_comuns]
```

Para a análise de cada índice separadamente, use o calendário de cada um sem mistura.

4. EDA - Parte 1: Qualidade dos Dados

Antes de qualquer análise financeira, precisamos garantir que os dados estão completos, consistentes e confiáveis. Esta etapa é frequentemente ignorada por iniciantes, e é onde os projetos falham.

4.1 Análise de Dados Faltantes

Ações podem ter dados faltantes por vários motivos: suspensão de negociação, IPO recente (empresa que entrou na bolsa depois de 2018), erros do provedor de dados, etc.

```
import matplotlib.pyplot as plt
import seaborn as sns

# =====
# DIAGNÓSTICO DE DADOS FALTANTES,S&P100
# =====

# Contagem e percentual de nulos por ação
nulos_sp = dados_sp100.isnull().sum()
pct_nulos = (nulos_sp / len(dados_sp100) * 100).round(2)

print('=== DADOS FALTANTES,S&P100 ===')
print(f'Total de ações: {dados_sp100.shape[1]}')
print(f'Ações sem nenhum dado faltante: {(pct_nulos == 0).sum()}')
print(f'Ações com algum dado faltante: {(pct_nulos > 0).sum()}')
print(f'\nAções com mais de 5% de dados faltantes:')
print(pct_nulos[pct_nulos > 5].sort_values(ascending=False))

# Visualização, mapa de calor de dados faltantes
# (usando missingno, pip install missingno)
try:
    import missingno as msno
    fig, ax = plt.subplots(figsize=(14, 5))
    msno.bar(dados_sp100, ax=ax, color='steelblue', fontsize=9)
    ax.set_title('Completeness of Data by Action,S&P100', fontweight='bold')
    plt.tight_layout()
    plt.savefig('missing_sp100.png', dpi=150)
    plt.show()
except ImportError:
    # Alternativa sem missingno
    completude = (1 - pct_nulos/100).sort_values()
    plt.figure(figsize=(12, 6))
    completude.plot(kind='barh', color='steelblue')
    plt.axvline(0.95, color='red', linestyle='--', label='95% de completude')
    plt.title('Completeness of Data by Action,S&P100')
    plt.xlabel('Proportion of data present (0 to 1)')
    plt.legend()
    plt.tight_layout()
    plt.savefig('completude_sp100.png', dpi=150)
    plt.show()

# Repetir para IBOV
nulos_ib = dados_ibov.isnull().sum()
pct_ib = (nulos_ib / len(dados_ibov) * 100).round(2)
print('\n=== DADOS FALTANTES,IBOV ===')
print(pct_ib[pct_ib > 5].sort_values(ascending=False))
```

4.2 Como Tratar os Dados Faltantes

Situação	Causa provável	O que fazer
Ação com 0% de dados faltantes	Ação negociada no período todo sem problemas	✅ Usar normalmente
Ação com 1–5% de dados faltantes	Feriados locais, suspensões temporárias	Preencher com o último valor disponível (forward fill)
Ação com 5–20% de dados faltantes	Ação listada depois de 2018 (IPO recente)	Avaliar se incluir, pode distorcer análise de 7 anos
Ação com >20% de dados faltantes	IPO muito recente, fusão, falência	❌ Remover do dataset, histórico insuficiente
Ação com todos os dados faltantes	Ticker errado ou não disponível	❌ Remover, verificar se o ticker está correto

```
# Estratégia de tratamento de missing values
```

```
# Passo 1: Remover ações com mais de 20% de dados faltantes
```

```
limite_remocao = 20
```

```
acoes_validas_sp = pct_nulos[pct_nulos <= limite_remocao].index
```

```
acoes_validas_ib = pct_ib[pct_ib <= limite_remocao].index
```

```
dados_sp100_clean = dados_sp100[acoes_validas_sp].copy()
```

```
dados_ibov_clean = dados_ibov[acoes_validas_ib].copy()
```

```
print(f'S&P100: {dados_sp100.shape[1]} → {dados_sp100_clean.shape[1]} ações válidas')
```

```
print(f'IBOV: {dados_ibov.shape[1]} → {dados_ibov_clean.shape[1]} ações válidas')
```

```
# Passo 2: Preencher dados faltantes restantes com forward fill
```

```
dados_sp100_clean = dados_sp100_clean.ffmpeg()
```

```
dados_ibov_clean = dados_ibov_clean.ffmpeg()
```

```
# Passo 3: Verificar se ainda há nulos (linhas iniciais podem ter NaN)
```

```
dados_sp100_clean = dados_sp100_clean.dropna(how='all')
```

```
dados_ibov_clean = dados_ibov_clean.dropna(how='all')
```

```
# Recalcular retornos com dados limpos
```

```
ret_sp100_clean = np.log(dados_sp100_clean / dados_sp100_clean.shift(1)).dropna()
```

```
ret_ibov_clean = np.log(dados_ibov_clean / dados_ibov_clean.shift(1)).dropna()
```

```
print(f'\nRetornos finais, S&P100: {ret_sp100_clean.shape}')
```

```
print(f'Retornos finais, IBOV: {ret_ibov_clean.shape}')
```

4.3 Identificação de Outliers nos Retornos

Retornos diários extremos (acima de $\pm 15\%$ em um único dia) são raros em ações normais e geralmente indicam eventos corporativos (splits, dividendos extraordinários) ou erros de dados.

```
from scipy import stats

# Detectar retornos extremos por ação
limite_outlier = 0.15 #  $\pm 15\%$  em um dia, ajuste conforme necessário

outliers_sp = (ret_sp100_clean.abs() > limite_outlier).sum()
print('Ações com retornos diários > 15% (S&P100):')
print(outliers_sp[outliers_sp > 0].sort_values(ascending=False).head(15))

# Investigar uma ação específica suspeita
acao_suspeita = 'TSLA' # exemplo
if acao_suspeita in ret_sp100_clean.columns:
    retornos_acao = ret_sp100_clean[acao_suspeita]
    dias_extremos = retornos_acao[retornos_acao.abs() > limite_outlier]
    print(f'\nDias com retorno extremo,{acao_suspeita}:')
    print(dias_extremos.sort_values(key=abs, ascending=False))

# Gráfico de distribuição de retornos vs. curva normal
plt.figure(figsize=(12, 5))

# Retornos do índice S&P100
plt.subplot(1, 2, 1)
sns.histplot(ret_idx_sp, bins=60, kde=True, color='navy', label='Distribuição real')
# Adicionar curva normal teórica
mu, sigma = ret_idx_sp.mean(), ret_idx_sp.std()
x = np.linspace(ret_idx_sp.min(), ret_idx_sp.max(), 100)
plt.plot(x, stats.norm.pdf(x, mu, sigma) * len(ret_idx_sp) * (ret_idx_sp.max() - ret_idx_sp.min()) / 60,
         'r--', lw=2, label='Normal teórica')
plt.title('Distribuição dos Retornos,S&P100')
plt.xlabel('Retorno Diário')
plt.legend()

plt.subplot(1, 2, 2)
sns.histplot(ret_idx_ib, bins=60, kde=True, color='green', label='Distribuição real')
mu2, sigma2 = ret_idx_ib.mean(), ret_idx_ib.std()
x2 = np.linspace(ret_idx_ib.min(), ret_idx_ib.max(), 100)
plt.plot(x2, stats.norm.pdf(x2, mu2, sigma2) * len(ret_idx_ib) * (ret_idx_ib.max() - ret_idx_ib.min()) / 60,
         'r--', lw=2, label='Normal teórica')
plt.title('Distribuição dos Retornos,IBOVESPA')
plt.xlabel('Retorno Diário')
plt.legend()

plt.tight_layout()
plt.savefig('distribuicao_retornos.png', dpi=150)
plt.show()

# O que observar: as caudas são mais pesadas que a normal? (fat tails = sim!)
print(f'\nCurtose S&P100: {ret_idx_sp.kurtosis():.2f} (normal = 0)')
print(f'Curtose IBOV: {ret_idx_ib.kurtosis():.2f} (normal = 0)')
print('Valores positivos = caudas gordas (fat tails),comum em finanças')
```

5. EDA - Parte 2: Explorando os Retornos das Ações

Com os dados limpos, chegou a hora de entender o comportamento de cada ação. Esta seção concentra as análises mais relevantes para a apresentação da semana.

5.1 Performance Normalizada, O Gráfico Mais Importante

Normalizar os preços na base 100 permite comparar visualmente o desempenho de ações com preços muito diferentes ao longo do tempo. Este é o gráfico que conta a história dos últimos 7 anos.

```
# Performance normalizada: todos começam em 100 no início do período
precos_norm_sp = (dados_sp100_clean / dados_sp100_clean.iloc[0] * 100)
indice_norm_sp = (indice_sp100 / indice_sp100.iloc[0] * 100)

plt.figure(figsize=(14, 8))

# Ações individuais em cinza claro (fundo)
for col in precos_norm_sp.columns:
    plt.plot(precos_norm_sp.index, precos_norm_sp[col],
             color='lightgray', linewidth=0.5, alpha=0.4)

# Destacar algumas ações relevantes
destaques = ['AAPL', 'MSFT', 'NVDA', 'TSLA']
cores_dest = ['blue', 'green', 'orange', 'purple']
for acao, cor in zip(destaques, cores_dest):
    if acao in precos_norm_sp.columns:
        plt.plot(precos_norm_sp.index, precos_norm_sp[acao],
                 color=cor, linewidth=1.5, label=acao, alpha=0.8)

# Índice em destaque total
plt.plot(indice_norm_sp.index, indice_norm_sp,
         color='navy', linewidth=3, label='S&P100 (Índice)')

# Marcar eventos importantes
plt.axvline('2020-03-23', color='red', linestyle=':', linewidth=1.5, alpha=0.7)
plt.text('2020-03-25', precos_norm_sp.max().max()*0.85, 'Mínimo\nCOVID',
        color='red', fontsize=9)

plt.axvline('2022-01-03', color='darkred', linestyle=':', linewidth=1.5, alpha=0.7)
plt.text('2022-02-01', precos_norm_sp.max().max()*0.70, 'Início\nCrise Juros',
        color='darkred', fontsize=9)

plt.title('Performance Normalizada, S&P100 (Base 100 em Jan/2018)',
         fontsize=14, fontweight='bold')
plt.ylabel('Valor (Base 100)', fontsize=12)
plt.xlabel('Data', fontsize=12)
plt.legend(fontsize=10, loc='upper left')
plt.grid(True, alpha=0.2)
plt.tight_layout()
plt.savefig('performance_normalizada_sp100.png', dpi=150)
plt.show()
```

5.2 Estatísticas Descritivas dos Retornos

As estatísticas descritivas dos retornos revelam o perfil de risco e retorno de cada ação, informação fundamental para entender o que o modelo de otimização terá disponível.

```
# Estatísticas completas dos retornos, por ação
stats = pd.DataFrame({
    'Retorno médio diário (%)': ret_sp100_clean.mean() * 100,
    'Retorno médio anualizado (%)': ret_sp100_clean.mean() * 252 * 100,
    'Volatilidade diária (%)': ret_sp100_clean.std() * 100,
    'Volatilidade anualizada (%)': ret_sp100_clean.std() * np.sqrt(252) * 100,
    'Sharpe aprox. anualizado': (
        ret_sp100_clean.mean() / ret_sp100_clean.std() * np.sqrt(252)),
    'Retorno mínimo diário (%)': ret_sp100_clean.min() * 100,
    'Retorno máximo diário (%)': ret_sp100_clean.max() * 100,
    'Assimetria (skewness)': ret_sp100_clean.skew(),
    'Curtose (kurtosis)': ret_sp100_clean.kurtosis(),
    'Dias negociados': ret_sp100_clean.count(),
}).round(4)

# Top 10 maior retorno médio anualizado
print('TOP 10, Maior Retorno Anualizado (S&P100):')
print(stats['Retorno médio anualizado (%)'].sort_values(ascending=False).head(10))

# Top 10 menor volatilidade (mais estáveis)
print('\nTOP 10, Menor Volatilidade Anualizada (S&P100):')
print(stats['Volatilidade anualizada (%)'].sort_values().head(10))

# Top 10 melhor Sharpe (melhor retorno ajustado por risco)
print('\nTOP 10, Melhor Sharpe Aproximado (S&P100):')
print(stats['Sharpe aprox. anualizado'].sort_values(ascending=False).head(10))

# Gráfico risco vs. retorno (Fronteira de dispersão)
plt.figure(figsize=(12, 8))
plt.scatter(stats['Volatilidade anualizada (%)'],
            stats['Retorno médio anualizado (%)'],
            alpha=0.6, s=60, color='steelblue')

# Anotar algumas ações de destaque
top_acoes = stats['Sharpe aprox. anualizado'].sort_values(ascending=False).head(5).index
for acao in top_acoes:
    plt.annotate(acao,
                (stats.loc[acao, 'Volatilidade anualizada (%)'],
                 stats.loc[acao, 'Retorno médio anualizado (%)']),
                textcoords='offset points', xytext=(5,5), fontsize=9)

plt.axhline(0, color='red', linestyle='--', linewidth=0.8, alpha=0.5)
plt.title('Risco × Retorno, Ações do S&P100 (7 anos)', fontweight='bold')
plt.xlabel('Volatilidade Anualizada (%)')
plt.ylabel('Retorno Médio Anualizado (%)')
plt.grid(True, alpha=0.3)
plt.tight_layout()
plt.savefig('risco_retorno_sp100.png', dpi=150)
plt.show()
```

5.3 Retorno por Período, Identificando Crises

Visualizar os retornos mensais do índice permite identificar rapidamente os períodos de crise e normalidade que estão presentes nos seus dados de 7 anos.

```
# Retorno mensal do índice
ret_mensal_sp = ret_idx_sp.resample('ME').sum() # soma dos retornos diários do mês
ret_mensal_ib = ret_idx_ib.resample('ME').sum()

fig, axes = plt.subplots(2, 1, figsize=(16, 8))

for ax, ret, titulo, cor_pos, cor_neg in [
    (axes[0], ret_mensal_sp, 'S&P100', 'steelblue', 'tomato'),
    (axes[1], ret_mensal_ib, 'IBOVESPA', 'darkgreen', 'firebrick'),
]:
    cores = [cor_pos if r > 0 else cor_neg for r in ret.values]
    ax.bar(range(len(ret)), ret.values * 100, color=cores, edgecolor='white', linewidth=0.3)
    ax.axhline(0, color='black', linewidth=0.8)
    ax.set_title(f'Retorno Mensal, {titulo}', fontweight='bold', fontsize=13)
    ax.set_ylabel('Retorno (%)')
    ax.set_xticks(range(0, len(ret), 6))
    ax.set_xticklabels(ret.index[:6].strftime('%b/%Y'), rotation=45, fontsize=9)
    ax.grid(True, alpha=0.2, axis='y')

    # Anotar o pior mês
    pior_idx = ret.values.argmin()
    pior_val = ret.values[pior_idx] * 100
    ax.annotate(f'{pior_val:.1f}%',
                xy=(pior_idx, pior_val), xytext=(pior_idx+5, pior_val-3),
                arrowprops=dict(arrowstyle='->', color='black'),
                fontsize=9, color='darkred')

plt.tight_layout()
plt.savefig('retorno_mensal_indices.png', dpi=150)
plt.show()

# Retorno acumulado por ano
ret_anual_sp = (1 + ret_idx_sp).resample('YE').prod() - 1
ret_anual_ib = (1 + ret_idx_ib).resample('YE').prod() - 1
print('\nRetorno anual S&P100:')
print((ret_anual_sp * 100).round(2))
print('\nRetorno anual IBOVESPA:')
print((ret_anual_ib * 100).round(2))
```

5.4 Correlação com o Índice, A Análise Central do Projeto

Para o index tracking, a correlação de cada ação com o índice é a informação mais valiosa da EDA. Ações com alta correlação com o índice são candidatas naturais para compor o portfólio de tracking.

```
# Correlação de cada ação com o índice
# Alinhar os índices de data primeiro
datas_comuns = ret_sp100_clean.index.intersection(ret_idx_sp.index)
ret_acoes_al = ret_sp100_clean.loc[datas_comuns]
ret_idx_al = ret_idx_sp.loc[datas_comuns]

# Calcular correlação de cada ação com o índice
corr_com_idx = ret_acoes_al.corrwith(ret_idx_al).sort_values(ascending=False)
```



```
print('TOP 15,Ações mais correlacionadas com o S&P100:')
print(corr_com_idx.head(15).round(4))

print('\nBOTTOM 10,Ações menos correlacionadas com o S&P100:')
print(corr_com_idx.tail(10).round(4))

# Gráfico de correlação com o índice
plt.figure(figsize=(14, 8))
cores = ['steelblue' if c > 0.7 else ('orange' if c > 0.5 else 'tomato')
        for c in corr_com_idx.values]
corr_com_idx.plot(kind='bar', color=cores, edgecolor='white', linewidth=0.3)
plt.axhline(0.7, color='green', linestyle='--', linewidth=1.5,
            label='Correlação 0.70 (referência)')
plt.axhline(0.5, color='orange', linestyle='--', linewidth=1.5,
            label='Correlação 0.50 (referência)')
plt.title('Correlação de Cada Ação com o Índice S&P100', fontweight='bold', fontsize=13)
plt.xlabel('Ação')
plt.ylabel('Correlação de Pearson')
plt.xticks(rotation=90, fontsize=7)
plt.legend()
plt.tight_layout()
plt.savefig('correlacao_com_indice_sp100.png', dpi=150)
plt.show()

# Quantos % das ações têm correlação > 0.7?
pct_alta_corr = (corr_com_idx > 0.7).mean() * 100
print(f'\n{pct_alta_corr:.1f}% das ações têm correlação > 0.7 com o índice')
```

6. EDA - Parte 3: Correlação Entre Ações e Análise por Setor

A correlação entre pares de ações é essencial para entender a estrutura do mercado. Ações muito correlacionadas entre si são redundantes para o portfólio, incluir as duas não traz benefício adicional de diversificação.

6.1 Matriz de Correlação Entre Ações

```
# Matriz de correlação entre todas as ações
corr_matrix = ret_sp100_clean.corr()

# Heatmap, para muitas ações, use uma amostra das mais representativas
# Selecionar as 30 ações com maior correlação com o índice
top30 = corr_com_idx.head(30).index
corr_top30 = ret_sp100_clean[top30].corr()

plt.figure(figsize=(14, 12))
import numpy as np
mask = np.triu(np.ones_like(corr_top30, dtype=bool)) # mostrar só triângulo inferior
sns.heatmap(
    corr_top30,
    mask=mask,
    annot=True, fmt='.2f',
    cmap='RdYlBu_r',
    center=0, square=True,
    linewidths=0.3,
    vmin=-1, vmax=1,
    cbar_kws={'shrink': 0.8},
    annot_kws={'size': 7}
)
plt.title('Correlação Entre as 30 Ações Mais Correlacionadas com o S&P100',
         fontweight='bold', fontsize=12)
plt.tight_layout()
plt.savefig('heatmap_correlacao_acoes.png', dpi=150, bbox_inches='tight')
plt.show()

# Encontrar pares com correlação muito alta (potencialmente redundantes)
pares_alta_corr = []
for i in range(len(corr_matrix.columns)):
    for j in range(i+1, len(corr_matrix.columns)):
        r = corr_matrix.iloc[i, j]
        if r > 0.90:
            pares_alta_corr.append({
                'Ação 1': corr_matrix.columns[i],
                'Ação 2': corr_matrix.columns[j],
                'Correlação': round(r, 3)
            })

df_pares = pd.DataFrame(pares_alta_corr).sort_values('Correlação', ascending=False)
print(f'Pares com correlação > 0.90: {len(df_pares)}')
print(df_pares.head(20).to_string(index=False))
```

6.2 Análise por Setor da Economia

Ações do mesmo setor tendem a se mover juntas (alta correlação intra-setor). Entender isso ajuda a interpretar os resultados do modelo de otimização e a fazer a apresentação mais rica.



Setores do S&P100 e seus representantes

- **Tecnologia:** AAPL, MSFT, NVDA, META, GOOGL, AMZN, maior peso, alta correlação entre si
- **Saúde:** JNJ, UNH, ABBV, PFE, MRK, defensivo, menos sensível ao ciclo econômico
- **Finanças:** JPM, BAC, WFC, GS, sensíveis a juros e ciclo econômico
- **Energia:** XOM, CVX, correlacionados com preço do petróleo (WTI/Brent)
- **Consumo básico:** PG, KO, WMT, defensivos, pouca variação em crises
- **Consumo discricionário:** AMZN, TSLA, MCD, sensíveis ao ciclo econômico

Para o IBOV, os setores mais representativos são:

- **Commodities:** VALE3, CSNA3, GGBR4, correlacionados com preço de minério e aço
- **Petróleo:** PETR4, correlacionado com preço do petróleo e câmbio
- **Financeiro:** ITUB4, BBDC4, BBAS3, dominam o índice em peso

```
# Adicionar setor de cada ação e analisar correlação média por setor
# Dicionário de setores, preencha com os setores reais
setores_sp100 = {
    'AAPL': 'Tecnologia', 'MSFT': 'Tecnologia', 'NVDA': 'Tecnologia',
    'META': 'Tecnologia', 'GOOGL': 'Tecnologia', 'GOOG': 'Tecnologia',
    'JPM': 'Financeiro', 'BAC': 'Financeiro', 'WFC': 'Financeiro',
    'JNJ': 'Saúde', 'UNH': 'Saúde', 'ABBV': 'Saúde', 'PFE': 'Saúde',
    'XOM': 'Energia', 'CVX': 'Energia',
    'PG': 'Cons. Básico', 'KO': 'Cons. Básico', 'WMT': 'Cons. Básico',
    'TSLA': 'Cons. Discric.', 'AMZN': 'Cons. Discric.', 'HD': 'Cons. Discric.',
    # ... adicionar os demais
}

# Correlação média com o índice por setor
df_corr_setor = pd.DataFrame({
    'acao': corr_com_idx.index,
    'corr_idx': corr_com_idx.values
})
df_corr_setor['setor'] = df_corr_setor['acao'].map(setores_sp100).fillna('Outros')

corr_por_setor = df_corr_setor.groupby('setor')['corr_idx'].agg(['mean', 'std', 'count'])
corr_por_setor.columns = ['Corr. média', 'Desvio', 'N ações']
print('\nCorrelação média com o índice por setor:')
print(corr_por_setor.sort_values('Corr. média', ascending=False).round(3))

# Boxplot de correlação por setor
plt.figure(figsize=(12, 6))
setores_ord = df_corr_setor.groupby('setor')['corr_idx'].median().sort_values(ascending=False).index
sns.boxplot(data=df_corr_setor, x='setor', y='corr_idx',
            order=setores_ord, palette='Blues')
plt.title('Correlação com o S&P100 por Setor', fontweight='bold')
plt.xlabel('Setor')
plt.ylabel('Correlação com o Índice')
plt.xticks(rotation=30)
plt.tight_layout()
plt.savefig('correlacao_por_setor.png', dpi=150)
plt.show()
```

7. EDA - Parte 4: Volatilidade e Períodos de Crise

Entender quando os mercados foram mais voláteis e por quê é fundamental para contextualizar os dados e fazer a apresentação mais rica. Os 7 anos do projeto (2018–2025) contêm vários eventos de mercado relevantes.

7.1 Linha do Tempo dos Principais Eventos

Período	Evento
Out/2018	Guerra comercial EUA × China
Mar/2020	Pandemia COVID-19
Nov/2020	Anúncio das vacinas
Jan–Dez/2022	Alta de juros nos EUA (Fed)
Nov/2022	Crise FTX (cripto)
Out/2023	Conflito Israel-Hamas
Jan/2024	Rally de IA (NVDA, MSFT)

7.2 Volatilidade Móvel, Como o Risco Muda ao Longo do Tempo

```
# Volatilidade móvel (rolling), janela de 21 dias úteis (~1 mês)
vol_sp = ret_idx_sp.rolling(window=21).std() * np.sqrt(252) * 100 # anualizada
vol_ib = ret_idx_ib.rolling(window=21).std() * np.sqrt(252) * 100

fig, axes = plt.subplots(2, 1, figsize=(14, 9), sharex=False)

for ax, vol, ret, titulo, cor in [
    (axes[0], vol_sp, ret_idx_sp, 'Volatilidade Móvel (21d), S&P100', 'navy'),
    (axes[1], vol_ib, ret_idx_ib, 'Volatilidade Móvel (21d), IBOVESPA', 'darkgreen'),
]:
    ax.fill_between(vol.index, vol, alpha=0.3, color=cor)
    ax.plot(vol.index, vol, color=cor, linewidth=1.5)
    ax.axhline(vol.mean(), color='gray', linestyle='--', linewidth=1,
               label=f'Média histórica ({vol.mean():.1f}%)')
    ax.set_title(titulo, fontweight='bold', fontsize=12)
    ax.set_ylabel('Volatilidade anualizada (%)')
    ax.legend(fontsize=10)
    ax.grid(True, alpha=0.2)

# Marcar COVID
covid_date = '2020-03-01'
if covid_date in vol.index.strftime('%Y-%m-%d'):
    ax.axvline(pd.Timestamp(covid_date), color='red',
               linestyle=':', linewidth=2, alpha=0.7, label='COVID-19')

plt.tight_layout()
plt.savefig('volatilidade_movel.png', dpi=150)
```

```
plt.show()

# Estatísticas de volatilidade
print(f'Volatilidade média histórica S&P100: {vol_sp.mean():.1f}% a.a.')
print(f'Volatilidade máxima S&P100: {vol_sp.max():.1f}% a.a.')
print(f'Data do pico de volatilidade: {vol_sp.idxmax().date()}')
print(f'\nVolatilidade média histórica IBOV: {vol_ib.mean():.1f}% a.a.')
print(f'Volatilidade máxima IBOV: {vol_ib.max():.1f}% a.a.')
```

7.3 Comparativo S&P100 vs. IBOVESPA

```
# Alinhar datas dos dois índices para comparação direta
datas_comuns_idx = ret_idx_sp.index.intersection(ret_idx_ib.index)
sp_al = ret_idx_sp.loc[datas_comuns_idx]
ib_al = ret_idx_ib.loc[datas_comuns_idx]

# Retorno acumulado comparativo
sp_acum = (1 + sp_al).cumprod() * 100
ib_acum = (1 + ib_al).cumprod() * 100

plt.figure(figsize=(14, 7))
plt.plot(sp_acum.index, sp_acum, color='navy', lw=2.5, label='S&P100 (USD)')
plt.plot(ib_acum.index, ib_acum, color='darkgreen', lw=2.5, label='IBOVESPA (BRL)')
plt.fill_between(sp_acum.index, sp_acum, ib_acum, alpha=0.05, color='gray')
plt.title('Retorno Acumulado Comparativo, S&P100 vs. IBOVESPA (Base 100)',
          fontweight='bold', fontsize=13)
plt.ylabel('Valor (Base 100)')
plt.legend(fontsize=12)
plt.grid(True, alpha=0.2)
plt.tight_layout()
plt.savefig('comparativo_sp100_ibov.png', dpi=150)
plt.show()

# Tabela resumo comparativa
resumo = pd.DataFrame({
    'S&P100': [
        f'{sp_al.mean()*252*100:.2f}%',
        f'{sp_al.std()*np.sqrt(252)*100:.2f}%',
        f'{(sp_al.mean()/sp_al.std()*np.sqrt(252)):.3f}',
        f'{sp_acum.iloc[-1]-100:.1f}%',
        f'{sp_al.min()*100:.2f}%',
        f'{sp_al.max()*100:.2f}%',
    ],
    'IBOVESPA': [
        f'{ib_al.mean()*252*100:.2f}%',
        f'{ib_al.std()*np.sqrt(252)*100:.2f}%',
        f'{(ib_al.mean()/ib_al.std()*np.sqrt(252)):.3f}',
        f'{ib_acum.iloc[-1]-100:.1f}%',
        f'{ib_al.min()*100:.2f}%',
        f'{ib_al.max()*100:.2f}%',
    ]
}, index=['Retorno anualizado', 'Volatilidade anualizada', 'Sharpe aproximado',
         'Retorno acumulado total', 'Pior dia', 'Melhor dia'])

print('\n=== COMPARATIVO S&P100 vs. IBOVESPA ===')
print(resumo.to_string())
```

8. Prompts de IA: Para Aprofundar o Entendimento dos Dados

Use estes prompts para aprofundar o entendimento financeiro e interpretar os resultados da EDA. Cole os dados reais do grupo entre colchetes [].



Prompt 1, Entender os Dados Financeiros

Sou estudante de Data Science e estou fazendo EDA em dados históricos de ações do S&P100 e IBOVESPA para um projeto de index tracking. Meus dados incluem preços diários de fechamento ajustado (Adj Close) de 2018 a 2025.

Me explique de forma prática:

1. Por que usamos retornos logarítmicos ao invés de preços em finanças?
2. O que significa dizer que retornos financeiros têm 'fat tails' (caudas gordas)?
3. O que é volatilidade anualizada e como interpretar um valor de 20% ao ano?
4. O que é o índice de Sharpe e o que significa um Sharpe de 0.8 vs. 1.5?
5. Por que ações do mesmo setor tendem a ter alta correlação entre si?
6. O que o evento COVID-19 (março/2020) representou em termos de retornos e volatilidade? O que esperar ver nos dados desse período?



Prompt 2, Interpretar os Resultados da Correlação

Analisei a correlação de cada ação do S&P100 com o índice e obtive os seguintes resultados:

[Cole aqui os resultados: 'TOP 10 correlações: MSFT=0.95, AAPL=0.93...' e 'BOTTOM 10: TSLA=0.45, BRK-B=0.50...']

1. Por que algumas ações têm correlação tão alta com o índice e outras tão baixa?
2. Para um modelo de index tracking, quais dessas ações são mais valiosas?
3. Ações com baixa correlação deveriam ser completamente ignoradas?
4. O que significa correlação negativa entre uma ação e o índice?
5. Como a correlação muda em períodos de crise vs. períodos normais?
6. Como apresentar essa análise de correlação para alguém sem background em finanças?



Prompt 3, Interpretar os Dados de Volatilidade

Calculei a volatilidade anualizada das ações do S&P100 e obtive:

[Cole aqui: 'Volatilidade média do índice: X%']

'Ações mais voláteis: TSLA=Y%, ...'

'Ações menos voláteis: KO=Z%, ...']

1. O que explica por que algumas ações são muito mais voláteis que o índice?
2. Para o index tracking, é melhor usar ações voláteis ou estáveis? Por quê?
3. O que o gráfico de volatilidade móvel nos mostra sobre o comportamento do mercado ao longo dos últimos 7 anos?
4. Como interpretar um pico de volatilidade de 80% ao ano (como em março/2020)?
5. Existe relação entre volatilidade e retorno esperado? Como comunicar isso na apresentação de forma intuitiva?



Prompt 4, Análise Comparativa S&P100 vs. IBOVESPA

Comparei os dois índices e obtive:

[Cole aqui os resultados do seu resumo comparativo, retorno anualizado, volatilidade, Sharpe, retorno acumulado total de cada índice]

1. O que justifica as diferenças de retorno entre S&P100 e IBOVESPA?
2. Qual índice é historicamente mais difícil de replicar por index tracking e por quê?
3. O fato de o IBOV ser em BRL e o S&P100 em USD cria alguma dificuldade na comparação? Como tratar isso?
4. Como a concentração em poucos setores (commodities e finanças no IBOV; tecnologia no S&P) afeta a estratégia de index tracking?
5. O que a diferença de Sharpe entre os dois índices nos diz sobre risco × retorno no mercado americano vs. brasileiro?



Prompt 5, Preparar a Narrativa para a Apresentação

Realizei a EDA completa dos dados do S&P100 e IBOVESPA para o projeto de index tracking. Principais achados:

[Descreva seus 3-5 principais insights da EDA aqui]

Exemplo: 'X% das ações têm correlação > 0.7 com o índice;
a volatilidade explodiu em março/2020 para Y% ao ano;
as ações do setor Z são as mais correlacionadas...'

Preciso apresentar esses resultados em [N] minutos para a turma.

1. Sugira uma narrativa de 3 atos para organizar a apresentação (gancho inicial → desenvolvimento → conclusão)
2. Quais dos meus insights são mais surpreendentes ou interessantes?
3. Que perguntas a turma provavelmente vai fazer e como responder?
4. Quais são os 5 gráficos mais importantes para incluir?

9. Checklist: O que Apresentar

A apresentação desta semana deve demonstrar que o grupo entende profundamente os dados, não só que coletou e limpou, mas que sabe o que os dados significam e o que revelam sobre o mercado.

9.1 O que os Professores/Avaliadores Querem Ver

Critério	O que demonstrar na apresentação
Entendimento do domínio	Explicar o que é o S&P100, o IBOVESPA, o que são retornos, por que usamos Adj Close, sem precisar que perguntem
Qualidade dos dados	Mostrar quantas ações tinham dados faltantes, o que foi feito, quais foram removidas e por quê, com critério justificado
EDA com insight	Não apenas mostrar gráficos, mas interpretá-los: 'este resultado significa que...' conectando dado com realidade do mercado
Contextualização temporal	Identificar os eventos históricos nos dados (COVID, juros, etc.) e mostrar como eles aparecem nos gráficos
Conexão com o projeto	Mostrar que a EDA já aponta quais ações são boas candidatas para o portfólio de tracking e por quê
Qualidade visual	Gráficos claros, com títulos, rótulos, legendas, padronizados e legíveis para a audiência

9.2 Checklist de Entregas Técnicas



Dados Coletados

- Preços diários de todas as ações do S&P100 (2018–2025)
- Preços diários de todas as ações do IBOVESPA (2018–2025)
- Dados do índice S&P100 (^OEX) e IBOVESPA (^BVSP)
- Retornos logarítmicos calculados para ações e índices
- Dados salvos localmente em CSV para não precisar baixar toda vez



Limpeza e Qualidade

- Análise de dados faltantes por ação, percentual e motivo quando possível
- Definição e aplicação do critério de remoção (ex: >20% de nulos)
- Forward fill aplicado para nulos residuais
- Identificação de retornos extremos (possíveis outliers / erros de dados)
- Documentação das decisões de tratamento com justificativa



Análises de EDA

- Gráfico de performance normalizada (base 100), ações + índice
- Estatísticas descritivas dos retornos por ação (média, std, Sharpe, mín/máx)
- Gráfico de retorno mensal do índice (barras verdes/vermelhas por mês)
- Retorno acumulado anual do índice por ano
- Distribuição dos retornos do índice (histograma vs. curva normal)
- Correlação de cada ação com o índice, gráfico de barras ranqueado
- Heatmap de correlação entre as ações mais relevantes
- Análise de volatilidade móvel ao longo dos 7 anos
- Comparativo S&P100 vs. IBOVESPA, tabela resumo e gráfico acumulado



Insights para Apresentar

- Quais ações são as mais correlacionadas com o índice (melhores candidatas para tracking)
- Quais setores da economia são mais fáceis de replicar
- Como COVID-19 e crise de juros 2022 aparecem nos dados
- Qual índice (S&P100 ou IBOV) parece mais difícil de replicar, e por quê
- Quantas ações foram removidas na limpeza e qual o impacto



Dica Final, Conte uma história com os dados

A diferença entre uma apresentação boa e uma excelente é a **narrativa**.

Não mostre os gráficos um por um como uma lista de resultados. Construa uma história:

****** Começamos com [N] ações, mas após a limpeza, trabalhamos com [M]. Ao explorar os dados, descobrimos que [insight 1]. O evento mais marcante nos dados foi [evento] em [data], quando [o que aconteceu]. Em termos de correlação, [insight 2]. Isso nos leva a concluir que, para o S&P100, as ações mais promissoras para o portfólio de tracking são aquelas do setor [X], pois [motivo]. ******

Isso mostra entendimento, não apenas execução técnica. Bom trabalho! 